

探索 Google Gemma 2 模型與應用

Simon Liu



劉育維 / Simon Liu

- Ocard 奧理科技 AI 工程師
- AI, ML, DL, LLM Architect and Engineer / Technical Writer / Speaker
- Try to use AI to do the application and help to solve the pain point by AI methods.
- My Personal Information:
 - Linkedin: <https://www.linkedin.com/in/simonliuyuwei/>
 - Personal Website: <https://simonliuyuwei-4ndgcf4.gamma.site/>



Table of Contents

- 01 Google Gemma 系列模型介紹
- 02 如何在 Google Colab 快速使用
Google Gemma 2 模型來進行測試
- 03 搭配 Google Cloud 服務, 讓
Google Gemma 結合 RAG 來進行服務應用
- 04 結語



“請依照工具提供的官方資訊為主，
我已盡力做好所有查核處理工作。”

技術隨時在變化

Section 1

Google Gemma 系列模型 介紹

Gemma LLM 模型的自我介紹

- 第一次釋出日期: Feb 21, 2024
- 模型名稱: Gemma 系列模型
 - 此模型由 Google 官方所開源出來的 SOTA AI 模型
- 模型開源狀況 / License:
 - Gemma 目前採用 Google 所撰寫的 License 授權方式 — Gemma Terms of Use, 統整相關內容並理解後, 是一個可商用的模型。



Medium 介紹

為何要釋出 Gemma 系列模型？

- 社群回饋機制與促進研究與創新：
 - 讓研究人員和開發者能深入探索 AI 技術，加速創新應用。
- 降低使用門檻：
 - Gemma 模型更小、更輕量，讓資源有限的開發者或企業也能輕鬆使用 Google 的 AI 技術。
- 特定任務優化：
 - Gemma 模型針對特定任務進行優化，例如自然語言理解或生成，能提供更精準、高效的解決方案。

目前 Gemma 種類

Gemma v1 / v2



- 高效能且輕量化的大型語言模型
- 主要可做對話式大型語言模型
- 各項評估上表現優良

RecurrentGemma

- 支援研究人員進行大批次的高效推理，採用循環神經網路和局部注意力機制提升記憶效率。
- 基準測試上成績與Gemma 2B模型相當，但是RecurrentGemma使用的記憶體量更少

CodeGemma

- 針對開發人員和企業的程式碼完成、生成和聊天工具使用情境
- 多程式語言能力，主要以Python、JavaScript、Java等各種熱門程式語言的程式碼撰寫建議

PaliGemma



- 視覺語言開放模型，能夠針對影像字幕、視覺問答、理解圖像內文字、物件偵測、物件切割的應用案例提供最佳化

Gemma 2 目前的模型能力比較

The performance is between that of GPT-3.5 and GPT-4.

	Meta Llama 3 8B	Meta Llama 2 7B	OpenAI GPT-4	OpenAI GPT-3.5	Gemma PT 9B	Gemma PT 27B	Google Gemma 7B-it	Google Gemini 1.5 Pro	MistralAI Mistral 7B Instruct
Open Source / Close Source	Open Source	Open Source	Close Source	Close Source	Open Source	Open Source	Open Source	Close Source	Open Source
MMLU (5-shot)	68.4	34.1	86.4	70.0	71.3	75.2	53.3	81.9	58.4
GPQA (0-shot)	34.2	21.7	35.7 (0-shot CoT)	28.1 (0-shot CoT)			21.4	41.5 (0-shot CoT)	26.3
HumanEval (0-shot)	62.2	7.9	67.0	48.1	40.2 (pass@1)	51.8 (pass@1)	30.5	71.9	36.6
GSM-8K (8-shot, CoT)	79.6	25.7	92.0 (5-shot CoT)	57.1 (5-shot)	68.6 (5-shot, maj@1)	74.0 (5-shot, maj@1)	30.6	91.7	39.9
MATH (4-shot, CoT)	30.0	3.8	52.9	34.1	36.6	42.3	12.2	58.5	11.0

未來生成式 AI 趨勢 by 簡立峰 (曾擔任Google台灣區董事總經理)

Tech Trends to Watch

- 模型網路化
 - 大模型化 (Gemini Ultra)
 - 小模型化 (Google Gemma)
 - 從單一到多模生態 (Multi-Modal - PaliGemma)
- 雙螢應用+AI
 - Doc, Excel, PPT, Mail, Photo, Chat, Search, ... "Agent"
 - Application: Google Workspace + Gemini
- Edge AI 新機載
 - AI phone, AI PC ...
- 機器人再啟
 - LLM生數據／人機對話交替
 - 白領到藍領全面影響



Section 2

如何在 Google Colab 快速使用 Google Gemma 2 模型來進行測試

你有幾種方式使用 Google Gemma 系列模型

Google  Extended

套件程式碼撰寫



Transformers



Keras



TensorFlow



PyTorch

寫程式碼，讓模型按照套件方式啟動

相關工具啟用





Ollama




透過工具啟動服務，透過 API 來使用

Hugging Face - Gemma 2

 **Hugging Face**

[Models](#) [Datasets](#) [Spaces](#) [Posts](#) [Docs](#) [Solutions](#) [Pricing](#) 

 **google's Collections**

Gemma 2 Release

PaliGemma Release

PaliGemma FT Models

CodeGemma Release

RecurrentGemma Release

Gemma release

BERT release

ALBERT release


ELECTRA release

Flan-T5 release


T5 release



Gemma 2 Release


updated 13 days ago



▲ Upvote **115**  +111


- Share collection
- View history
- Collection guide
- Browse collections



 **google/gemma-2-9b**


Text Generation • Updated 8 days ago •  50.2k •  408



 **google/gemma-2-9b-it**

Text Generation • Updated 8 days ago •  61.6k •  239

 **google/gemma-2-27b**

Text Generation • Updated 8 days ago •  45.2k •  119

 **google/gemma-2-27b-it**

Text Generation • Updated 8 days ago •  72.6k •  286

Note ^ Models in transformers format

<https://huggingface.co/collections/google/gemma-2-release-667d6600fd5220e7b967f315>

Kaggle - Gemma 2

≡ kaggle

+ Create

🏠 Home

🏆 Competitions

📁 Datasets

👤 Models

🔗 Code

💬 Discussions

📖 Learn

⌵ More

📅 View Active Events

🔍 Search

Sign In

Register



GOOGLE · PUBLISHED ON 2024.06.27

126

Download

Code



Gemma 2

google/gemma-2

Gemma is a family of lightweight, state-of-the-art open models from Google, built from the same research and technology used to create the Gemini models.

Model Card

Code (4)

Discussion (2)

Competitions



Access Gemma 2 on Kaggle

To access Gemma 2 on Kaggle, you need to first request access.

Request Access

Model Details

Gemma 2 model card

Model Page: [Gemma](#)

Resources and Technical Documentation:

- [Responsible Generative AI Toolkit](#)
- [Gemma on Kaggle](#)
- [Gemma on Vertex Model Garden](#)

Terms of Use: [Terms](#)

Tags

TASK

Text Generation

Text-To-Text Generation

LANGUAGE

English

Usability

8.00

<https://www.kaggle.com/models/google/gemma-2>

- Ollama 是一個開源軟體，讓使用者可以在自己的硬體上運行、創建和分享大型語言模型服務。
- 這個平台適合在地端運行模型，因為它不僅可以保護隱私，還允許使用者透過命令行介面輕鬆地設置和互動。
- Ollama 支援非常多種模型，並提供彈性的客製化選項，例如從其他格式導入模型並設置參數。



Gemma 2 Model in Ollama



文件介紹

gemma2

Google Gemma 2 is now available in 2 sizes, 9B and 27B.

9B 27B

↓ 332.9K Pulls ⌚ Updated yesterday

9b	63 Tags	ollama run gemma2	
Updated yesterday ff02c3702f32 · 5.4GB			
model	arch gemma2 · parameters 9.24B · quantization Q4_0		5.4GB
params	{ "stop": ["<start_of_turn>", "<end_of_turn>"] }		65B
license	Gemma Terms of Use Last modified: February 21, 2024 By usi...		8.4kB
template	<start_of_turn>user {{ if .System }}{{ .System }} {{ end }}...		136B

Two sizes: 9B and 27B parameters

- 9B Parameters `ollama run gemma2`
- 27B Parameters `ollama run gemma2:27b`

Ollama Python Library

The Ollama Python library provides the easiest way to integrate Python 3.8+ projects with [Ollama](https://ollama.com).

Prerequisites

You need to have a local ollama server running to be able to continue. To do this:

- Download: <https://ollama.com>
- Run an LLM: <https://ollama.com/library>
 - Example: `ollama run llama2`
 - Example: `ollama run llama2:70b`

Then:

```
curl https://ollama.ai/install.sh | sh
ollama serve
```

Next you can go ahead with `ollama-python`.

Install

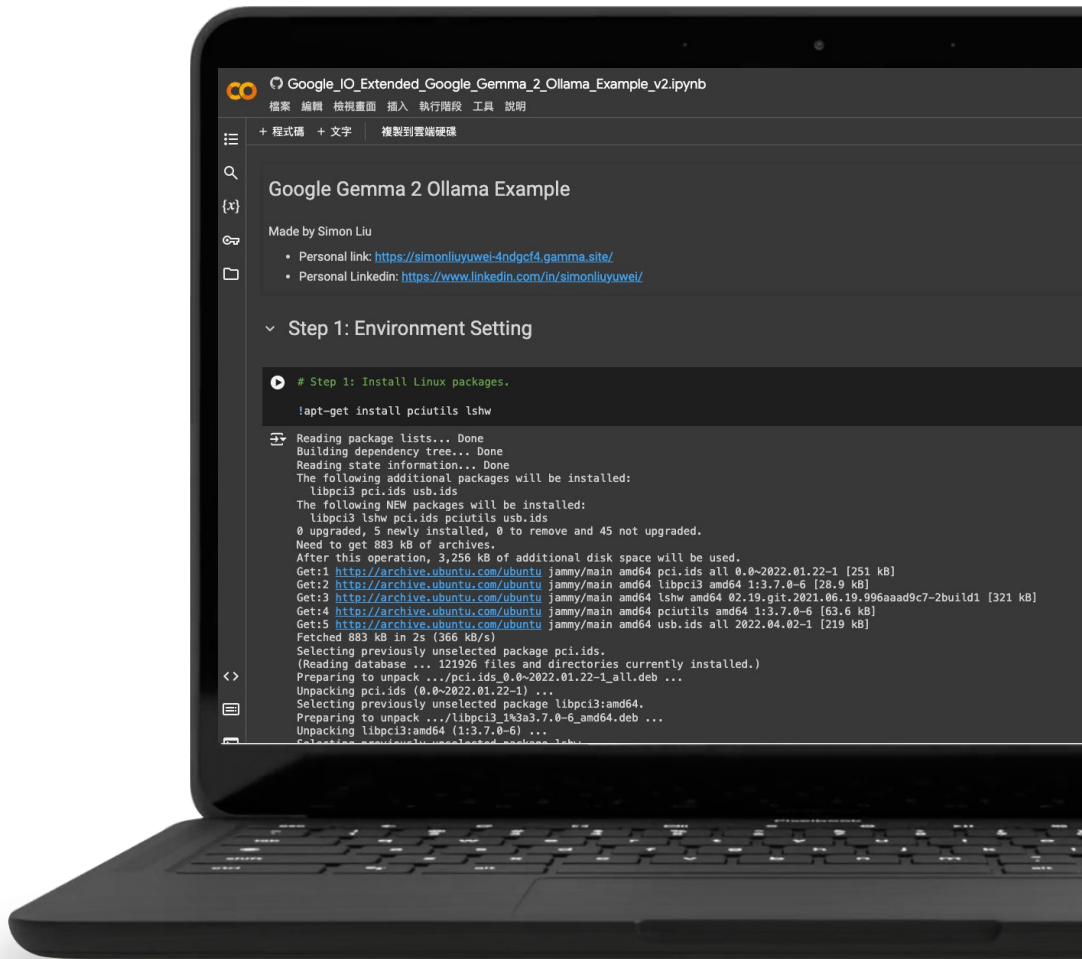
```
pip install ollama
```

Usage

```
import ollama
response = ollama.chat(model='llama3', messages=[
  {
    'role': 'user',
    'content': 'Why is the sky blue?',
  },
])
print(response['message']['content'])
```


Let's demo it!

<https://tinyurl.com/gemma-example>



Section 3

搭配 Google Cloud 服務，
讓 Google Gemma 結合 RAG 來
進行服務應用

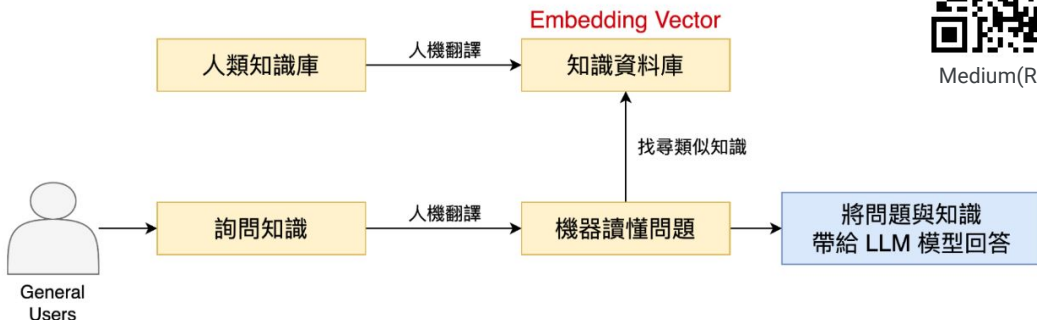
快速介紹：什麼是 RAG / Fine-Tune？



Medium(RAG)


RAG (Embedding)

當人類詢問問題時，找尋說明書了解知識後，再回覆問題。



Fine-Tune Model

類似小孩子學習新知的概念，經過學習，就能夠得到新知。



DIY RAG search

Preparation



Collection

Web Crawler, Files,
DBs, Connectors

How do I get my data,
from wherever it is, into
the pipeline?



Parsing

Document AI or similar

How do I process my
data to extract text
or other information?



Chunking

How should I segment
while preserving
meaning?



Embedding

PaLM or similar

Which vector
dimensions? How do I
encode Multi-modal?



Storage

Many options

Which vector database?
How will it perform?

Runtime



Query

Do I need to spell check?
What about rewording?



Search

Matching engine

Is ANN enough? Should we
use IF or HNSW? What is the
best similarity metric?



Summarization & Conversation

Gemini API or similar

Keeping context windows,
Prompt Engineering,
Tuning, Require citations



Serving

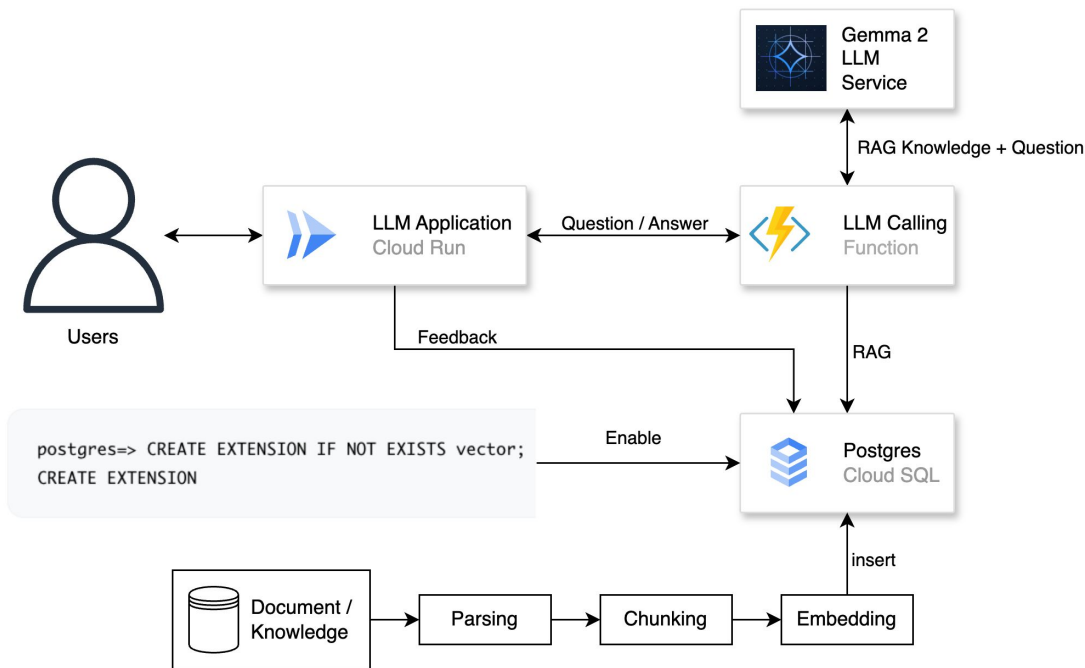
Cloud host

Will my serving API scale to
demand? Is my infra secure?




Pgvector in Google Cloud

Open-source vector similarity search for Postgres Database




Google Cloud Vertex AI Vector Search

Google Cloud 的 Embedding Vector Database 服務

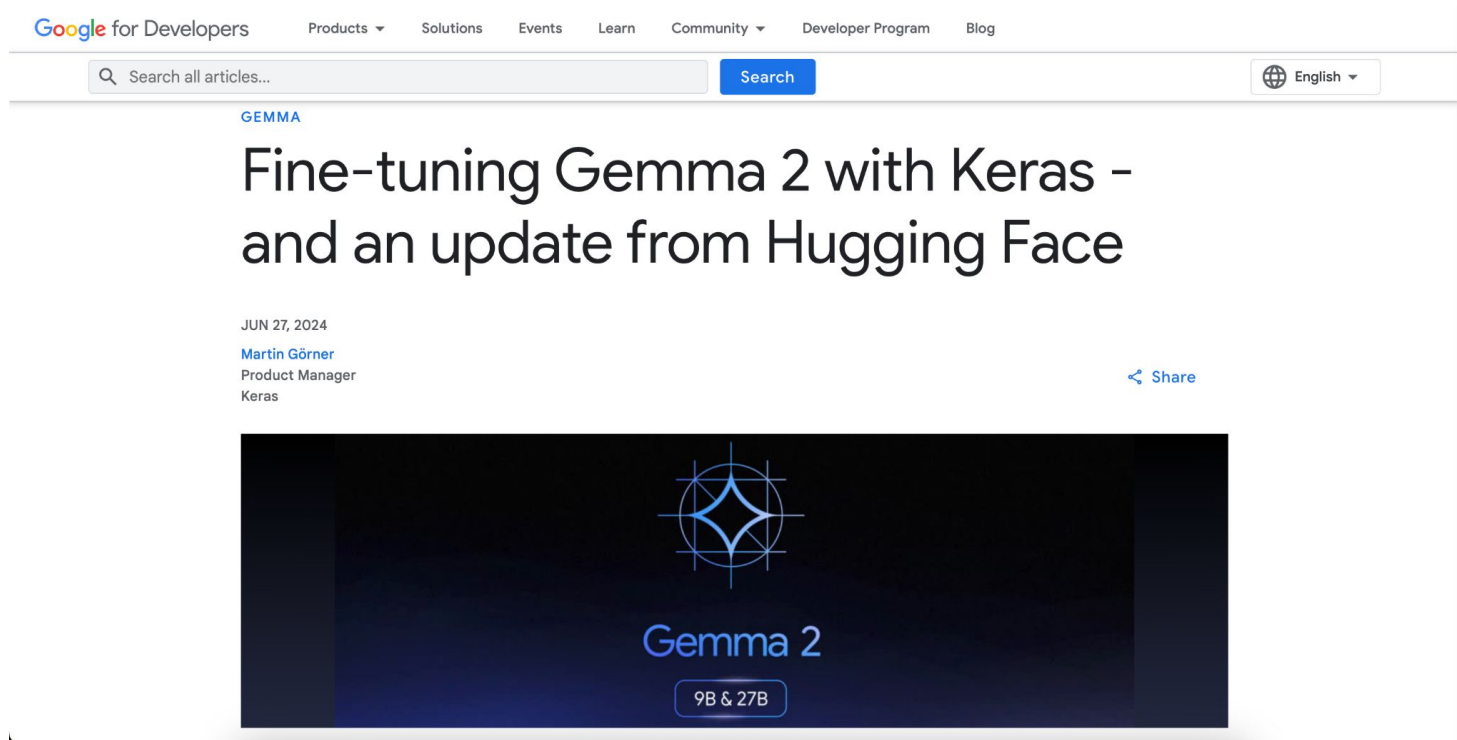


Google Cloud Vertex AI Search

Google Cloud 全託管式的知識輔助搜尋引擎服務



Fine-Tuning Google Gemma 2 Model



到底什麼時候 Fine-Tune ?

以法律相關背景做舉例：

法律判例機器人

VS

法律條文機器人

透過過去判決經驗，來判斷
是否可以推論可能結果



根據過往案例來判斷



RAG 讓判例能夠快速準確被
檢索出來，且經常會被更新

透過法律條文，來了解此法
律案件違反哪條規定



須先理解和讀懂法律條文




先 **Fine-Tune** 讀懂條文，再
來幫助其他人綜合判斷

Section 4

結語

- Gemma 2 以超越 GPT-3.5, 接近 GPT-4 的能力下, 提供相關 AI 模型生成能力來完成需求。
- 透過工具來啟動 Gemma 服務
 - 第三方 API 工具: Ollama / Llama-cpp / VLLM 等
 - Python 套件: Tensorflow / Pytorch / KerasNLP / Transformer
- 搭配 Google Cloud 服務, 來使用 RAG 等方式, 讓產品化能夠做的更好
 - Pgvector Database in Google Cloud SQL
 - Google Cloud Vertex AI Vector Search / Vertex AI Search

Thank You



Simon Liu 劉育維

AI Engineer